TOEFL Mate

Rangkuman belajar dan briefing presentasi demo

UTS Pengantar Generative AI | Panduan internal kelompok

Dokumen ini membantu anggota memahami masalah, alur RAG, demo, evaluasi, dan keterbatasan. Status teknis mencerminkan hasil kerja dan pengujian terakhir yang terdokumentasi; cek kembali aplikasi sebelum presentasi.

Ringkasan satu menit

TOEFL Mate adalah prototipe asisten belajar yang menjawab pertanyaan tentang TOEFL dengan mengambil potongan dari dokumen yang telah diindeks. Sistem memakai Retrieval-Augmented Generation (RAG): mencari konteks yang relevan, lalu memberikan konteks tersebut kepada model bahasa untuk menyusun jawaban dan sitasi.

- **Masalah:** mencari informasi pada dokumen TOEFL yang panjang dapat memakan waktu, sedangkan model bahasa tanpa konteks sumber dapat memberikan informasi yang tidak terverifikasi.
- **Solusi:** gabungkan pencarian semantik pada dokumen dan generasi jawaban dalam antarmuka chat Streamlit.
- **Nilai utama:** jawaban dapat ditelusuri ke sumber dan halaman, tetapi tetap harus dicek terhadap teks asli.
- **Status:** prototipe untuk demo; correctness dan groundedness belum divalidasi manusia secara menyeluruh.

Kalimat pembuka yang dapat digunakan

“Kami mengembangkan TOEFL Mate, asisten belajar berbasis RAG. Alih-alih hanya mengandalkan ingatan model bahasa, aplikasi mencari konteks dari dokumen yang telah diindeks dan menggunakannya saat menyusun jawaban.”

1. Konsep utama yang perlu dikuasai

- **LLM:** model bahasa yang menghasilkan teks berdasarkan prompt dan konteks; tetap bisa salah atau membuat klaim yang tidak didukung.
- **RAG:** pendekatan yang menggabungkan retrieval (mencari informasi) dengan generation (menyusun respons). RAG mengupayakan jawaban yang lebih terarah pada sumber, bukan menjamin bebas halusinasi.
- **Chunk:** potongan teks dari dokumen. Overlap adalah bagian yang berulang antara potongan berdekatan untuk membantu mempertahankan konteks di batas chunk.
- **Embedding:** representasi numerik teks. Teks yang secara semantik mirip diharapkan memiliki representasi yang berdekatan.
- **Vector store:** penyimpanan embedding untuk pencarian kemiripan; proyek ini menggunakan ChromaDB.
- **Top-k:** jumlah kandidat konteks teratas yang diminta. K lebih besar dapat menambah konteks, tetapi juga berpotensi menambah noise dan biaya token.
- **Groundedness:** apakah klaim dalam jawaban benar-benar didukung sumber. Sitasi yang lokasinya ditemukan belum membuktikan bahwa klaim didukung.

2. Alur sistem: dari dokumen sampai jawaban

Tahap persiapan / ingestion

PDF → ekstraksi teks per halaman dengan PyMuPDF → normalisasi dan pemotongan teks → embedding lokal dengan Sentence Transformers → simpan vektor serta metadata sumber dan halaman di ChromaDB.

Tahap saat pengguna bertanya

Pertanyaan di Streamlit → query diperkaya istilah tertentu → query diubah menjadi embedding → pencarian top-k dan penyaringan berdasarkan jarak → konteks diberikan ke Groq bersama instruksi → jawaban dan sitasi ditampilkan.

Model embedding yang dikonfigurasi secara default adalah **all-MiniLM-L6-v2**. Model generasi dipilih melalui **GROQ_MODEL**; jangan menyebut nama model tertentu tanpa melihat konfigurasi aktual. Embedding dilakukan lokal; potongan konteks yang dipakai generasi dikirim ke penyedia Groq.

Jarak L2 yang lebih kecil menunjukkan kemiripan vektor yang lebih tinggi dalam pengaturan indeks ini. **Distance bukan probabilitas kebenaran atau skor confidence.**

3. Fungsi komponen dan berkas penting

- **app.py:** antarmuka Streamlit, pengaturan pengguna, chat, dan tampilan konteks.
- **src/ingestion.py dan scripts/ingest_pdf.py:** pemrosesan PDF dan pembangunan koleksi kandidat.
- **src/embeddings.py dan src/retriever.py:** embedding, penyimpanan/pencarian ChromaDB, dan pemeriksaan manifest jika tersedia.
- **src/prompts.py dan src/generator.py:** instruksi untuk model dan pemanggilan generasi melalui Groq.
- **src/evaluation.py dan scripts/evaluate.py:** perhitungan metrik serta penyimpanan hasil evaluasi.
- **tests/:** pengujian otomatis; **reports/:** dokumen laporan dan catatan perbaikan.

4. Cara menjalankan sebelum demo

Dari terminal pada direktori proyek, jalankan:

```
python -m streamlit run app.py
```

Buka http://localhost:8501. Pastikan lingkungan Python dan dependensi tersedia, koleksi yang dipilih sudah terisi, serta GROQ_API_KEY sudah dikonfigurasi. Jangan tampilkan isi .env atau API key pada rekaman.

Ingestion membangun **koleksi kandidat**, bukan otomatis mengganti koleksi aktif. Jangan melakukan ingestion ulang saat demo hanya untuk menunjukkan proses. Jika kandidat baru memang diperlukan, periksa hasilnya lalu atur CHROMA_COLLECTION secara eksplisit sesuai README. Indeks lama tanpa manifest lengkap berstatus UNKNOWN, bukan terbukti cocok.

5. Skenario demo live yang disarankan

- **Persiapan:** buka aplikasi sebelum merekam, cek status indeks dan API, perbesar tampilan, dan siapkan koneksi cadangan.
- **Mulai:** ketik “Halo”. Respons sapaan tidak harus memiliki sitasi.
- **Pertanyaan faktual:** “Apa saja empat bagian tes TOEFL iBT?” Tunjukkan jawaban dan sitasinya jika muncul.
- **Periksa sumber:** buka “Konteks hasil pencarian” dan bandingkan teks yang ditampilkan dengan klaim. Jika tidak mendukung, katakan secara jujur.
- **Follow-up:** “Jelaskan bagian kedua tadi.” Versi sekarang dirancang meminta klarifikasi untuk rujukan ordinal ambigu; lanjutkan dengan “Maksud saya bagian Listening.”
- **Di luar cakupan:** “Berapa biaya pendaftaran TOEFL tahun 2026 di Jakarta?” Harapannya sistem tidak mengarang harga terkini; respons aktual perlu diamati.
- **Pengaturan:** tunjukkan pilihan bahasa, gaya, tingkat, atau top-k jika waktu cukup. Hindari menjanjikan respons tertentu sebelum pengujian live.

6. Evaluasi: apa yang boleh dan tidak boleh diklaim

Pada pengujian otomatis terakhir yang terdokumentasi, **67 test lulus dan 1 warning**. Test membantu memeriksa perilaku kode, bukan membuktikan semua jawaban benar atau didukung sumber.

Hasil historis V2 pada demo outline: **Hit@5 0,5600; Precision@5 0,1920; Hit@3 0,4400; Precision@3 0,2000**. Hasil itu menggunakan label historis berbasis halaman, bukan label source-aware yang terverifikasi. Karena itu angka tersebut bersifat historis dan tidak boleh dibandingkan langsung dengan evaluasi source-aware baru. Run k=5 mencatat satu rate-limit; k=3 mencatat 30 generation berhasil.

- **Hit@k:** proporsi pertanyaan berlabel yang memiliki minimal satu hasil relevan di top-k. Pada evaluator baru, relevansi memakai pasangan sumber dan halaman.
- **Precision@k:** jumlah chunk hasil top-k yang cocok dengan label dibagi k; chunk duplikat dihitung terpisah. Evaluator baru mengecualikan label yang sumbernya tidak diketahui dan retrieval yang gagal.
- **Validitas lokasi sitasi:** apakah pasangan sumber-halaman sitasi ditemukan dalam konteks hasil pencarian. Ini bukan penilaian apakah isi konteks mendukung setiap klaim.
- **OOS:** indikator frasa penolakan hanya mendeteksi kata-kata tertentu, bukan ukuran akurasi penanganan pertanyaan di luar cakupan.

Correctness, groundedness, dan dukungan klaim oleh sitasi masih memerlukan review manusia. Belum ada re-scoring source-aware atas hasil historis.

7. Keterbatasan yang perlu disampaikan

- Jawaban tergantung isi dan edisi dokumen dalam indeks; informasi terbaru seperti biaya atau perubahan format harus dicek pada sumber resmi terkini.
- Retrieval dapat melewatkan konteks yang tepat; model tetap dapat salah, dan sumber/halaman yang benar belum menjamin interpretasi benar.
- Manifest indeks lama mungkin tidak lengkap; kompatibilitas model embedding dengan indeks berstatus UNKNOWN sampai dibuktikan.
- Follow-up ordinal ditangani secara konservatif dengan permintaan klarifikasi, bukan pemahaman percakapan sempurna.
- Evaluasi manusia, checkpoint/resume evaluasi, dan verifikasi deploy bersih masih terbuka.

8. Rencana presentasi sekitar lima menit

- **0:00–0:30 | Pembukaan:** masalah, tujuan, dan gambaran singkat aplikasi.
- **0:30–1:15 | Arsitektur:** bedakan ingestion dan alur pertanyaan; jelaskan chunk, embedding, vector store, retrieval, dan generasi.
- **1:15–3:20 | Demo:** sapaan, satu pertanyaan faktual, buka konteks, follow-up, dan satu pertanyaan di luar cakupan. Sesuaikan dengan waktu respons.
- **3:20–4:15 | Evaluasi:** jelaskan test otomatis, contoh metrik historis dengan batas label, serta kebutuhan review manusia.
- **4:15–5:00 | Kesimpulan:** manfaat, keterbatasan, dan langkah berikutnya.

Pembagian peran contoh: anggota 1 membuka dan menjelaskan masalah; anggota 2 menjelaskan arsitektur; anggota 3 mengoperasikan demo; anggota 4 menjelaskan evaluasi dan penutup. Sesuaikan dengan jumlah anggota.

9. Pertanyaan dosen yang mungkin muncul

Mengapa memakai RAG, bukan langsung bertanya ke LLM?
RAG memberi model konteks spesifik dan memungkinkan penelusuran sumber. Akan tetapi hasil tetap perlu diverifikasi.

Apa bedanya embedding dan LLM?
Embedding mengubah teks menjadi vektor untuk pencarian kemiripan; LLM menyusun jawaban berdasarkan pertanyaan dan konteks.

Apakah sitasi berarti jawaban pasti benar?
Tidak. Kita perlu membaca sumber untuk memastikan teksnya benar-benar mendukung klaim dan tidak salah konteks.

Kenapa k=5 tidak otomatis lebih baik daripada k=3?
K lebih besar dapat menemukan lebih banyak konteks, tetapi juga dapat membawa informasi yang tidak relevan. Metrik dan kualitas jawaban harus dievaluasi.

Apa yang terjadi ketika informasi tidak ada?
Instruksi meminta model mengakui keterbatasan; perilaku aktual masih perlu diuji dan indikator frasa penolakan bukan jaminan keberhasilan.

Apakah angka tes menunjukkan akurasi chatbot?
Tidak. Test otomatis memeriksa perilaku terprogram; correctness dan groundedness memerlukan evaluasi jawaban dan sumber oleh manusia.

10. Checklist akhir kelompok

- Semua anggota memahami perbedaan retrieval dan generation serta dapat menjelaskan keterbatasan tanpa membaca naskah.
- Coba prompt demo, cek sitasi, siapkan jawaban cadangan jika API gagal, dan jangan tampilkan rahasia.
- Pastikan klaim angka sesuai artefak dan tanggal pengujian; jangan menyebut hasil historis sebagai evaluasi source-aware.
- Cek lisensi dokumen sebelum publikasi, serta pastikan deployment dan video sesuai kondisi aktual.