TOEFL Mate: RAG Study Assistant

Laporan Metodologi dan Evaluasi

UTS Pengantar Generative AI — 30 October 2026

■■ STATUS: EVALUASI PARSIAL — run status: PARTIAL_OR_NOT_RUN. Sebagian metrik generation dapat memiliki kegagalan API dan harus dibaca bersama status per item.

1. Tujuan dan Pertanyaan Penelitian

Proyek ini bertujuan membangun chatbot pembelajaran TOEFL berbasis pipeline Retrieval-Augmented Generation (RAG) yang menjawab pertanyaan berdasarkan dokumen "The Official Guide to the TOEFL Test, Fourth Edition" (ETS, 2012).

Pertanyaan penelitian:
1. Seberapa efektif pipeline RAG dalam menemukan konteks yang relevan dari dokumen TOEFL?
2. Seberapa akurat jawaban yang dihasilkan LLM berdasarkan konteks yang di-retrieve?
3. Apakah sistem mampu mengakui keterbatasan saat informasi tidak tersedia?
4. Bagaimana pengaruh parameter retrieval (top_k) terhadap kualitas jawaban?

2. Sumber Data dan Batasan

Sumber data adalah PDF yang tercatat pada manifest indeks aktif; evaluasi harus menyebutkan sumber yang benar-benar diindeks. Dokumen Official Guide yang digunakan adalah edisi 2012, sehingga format/kebijakan TOEFL mungkin telah berubah. Teks diekstrak menggunakan PyMuPDF dengan nomor halaman 1-based berdasarkan indeks PDF (bukan nomor cetak buku).

Batasan:
- Cakupan hanya bergantung pada PDF yang benar-benar diindeks; sumber aktif harus diperiksa melalui manifest indeks.
- Kualitas ekstraksi tergantung pada kualitas PDF (bukan OCR).
- Evaluasi otomatis terbatas; beberapa metrik memerlukan penilaian manusia.
- Dokumen berhak cipta; hanya kutipan seperlunya untuk penjelasan.

3. Arsitektur dan Konfigurasi RAG

Parameter	Nilai
Embedding Model	all-MiniLM-L6-v2
LLM Model (Groq)	openai/gpt-oss-120b
Chunk Size	500
Chunk Overlap	100
Top-K Retrieval	5
Relevance Threshold	1.5
Vector Store	ChromaDB (L2 distance)

PDF Extractor	PyMuPDF (fitz)

Alur pipeline: PDF → Ekstraksi teks per halaman → Pembersihan → Chunking → Embedding lokal (Sentence Transformers) → ChromaDB → Query embedding → Top-K retrieval → Prompt construction → Groq LLM → Jawaban dengan sitasi halaman.

4. Proses Pembuatan Dataset Uji

Dataset berisi 30 pertanyaan yang disusun berdasarkan isi dokumen PDF:
- 10 pertanyaan faktual dengan jawaban eksplisit di dokumen.
- 10 pertanyaan konseptual yang membutuhkan sintesis informasi.
- 5 pertanyaan untuk menguji relevansi retrieval dan akurasi sitasi.
- 5 pertanyaan di luar cakupan dokumen.

Setiap item memiliki id, category, question, reference_answer (jika relevan), relevant_pages, dan catatan penilai. Status verifikasi manusia label harus dicatat pada dataset atau lembar audit terpisah; jangan menyatakan label telah diverifikasi bila bukti itu belum tersedia.

5. Definisi Metrik dan Rubrik

Metrik	Definisi	Jenis
Recall@K	1 jika setidaknya satu halaman relevan muncul di top-K; rata-rata per query	Otomatis
Precision@K	Jumlah halaman relevan di top-K / K; rata-rata per query	Otomatis
Citation Accuracy	Sitasi halaman benar / total sitasi	Otomatis
Out-of-Scope Handling	Jawaban yang mengakui keterbatasan / total pertanyaan OOS	Otomatis
Latency	Waktu respons rata-rata per pertanyaan (detik)	Otomatis
Answer Correctness	Jawaban memenuhi rubrik / total jawaban dinilai	Manual
Groundedness	Klaim didukung konteks / total klaim faktual	Manual

Rubrik Answer Correctness (manual):
- CORRECT: Jawaban sesuai reference_answer dan mencakup poin utama.
- PARTIALLY_CORRECT: Jawaban benar sebagian atau kurang lengkap.
- INCORRECT: Jawaban salah atau tidak relevan.
- NOT_RATED: Belum dinilai.

6. Hasil Evaluasi

Metrik	Nilai	Sampel	Definisi / Status
recall_at_k	**0.5600**	25	Fraction of queries where at least one relevant page appeared in top-k results
precision_at_k	**0.1920**	25	Average (relevant pages in top-k / k)
citation_accuracy_micro	**0.3250**	40	Total cited pages matching labeled pages / all cited pages; location validity is recorded separately
citation_coverage	**0.5600**	25	In-scope answers with at least one parseable citation / in-scope questions
out_of_scope_handling	**0.8000**	5	OOS questions correctly acknowledged / total OOS questions
avg_generation_latency_seconds	**10.3043**	29	Average Groq generation latency for successful answers (seconds)
avg_retrieval_latency_seconds	**0.0781**	30	Average local retrieval latency, may include cold embedding load
avg_end_to_end_latency_seconds	**10.6373**	29	Average retrieval-to-answer latency for successful answers (seconds)
answer_correctness	**REQUIRES_HUMAN_REVIEW**	?	Fraction of answers matching reference answer rubric (manual)
groundedness	**REQUIRES_HUMAN_REVIEW**	?	Fraction of factual claims supported by retrieved context (manual)

Evaluasi baseline (top_k=5) dijalankan pada: 2026-10-30T12:58:33.146554+00:00

6.1 Perbandingan Eksperimen: top_k=3 vs top_k=5

Sesuai Section 7 PRD, dilakukan perbandingan variasi parameter retrieval antara baseline (top_k=5) dan variasi (top_k=3) menggunakan dataset berlabel yang sama (25 pertanyaan berlabel target):

Konfigurasi	Recall@K	Precision@K	Analisis Trade-off
Variasi (top_k=3)	**0.4400**	**0.2000**	Precision lebih tinggi karena ruang chunk lebih sempit, namun Recall lebih rendah.
Baseline (top_k=5)	**0.5600**	**0.1920**	Recall naik signifikan (+33% relatif) dengan trade-off penurunan precision.

7. Analisis Contoh

7.1 Contoh Berhasil (Retrieval Relevan)

Query ID: fact_02 (factual)

Pertanyaan: Berapa jumlah jenis pertanyaan pada Reading section tes TOEFL iBT dan dibagi ke dalam berapa kategori keterampilan?

Retrieved PDF Pages: [52, 359, 475, 247, 10]

Retrieved Chunk Distances (L2): [0.9195, 0.9247, 0.9474, 0.9576, 0.9878]

Jawaban: **Jumlah jenis pertanyaan pada Reading section TOEFL iBT:** **10 jenis** **Pembagian ke dalam kategori keterampilan:** **3 kategori** | Kategori keterampilan | Deskripsi singkat | |----------|----------| | **Basic Information** | Menguji kemampuan menemukan fakta langsung d...

Analisis: Vektor embedding query berhasil memetakan semantik pertanyaan ke halaman yang tepat dalam top-5 hasil ChromaDB.

7.2 Contoh Kurang Tepat / Retrieval Miss

Query ID: fact_01 (factual)

Pertanyaan: Berapa skala skor total untuk tes TOEFL iBT dan berapa rentang skor untuk setiap bagiannya?

Retrieved PDF Pages: [207, 36, 204, 298, 36]

Retrieved Chunk Distances (L2): [0.921, 0.9368, 0.969, 0.9782, 0.9796]

Analisis Kesalahan: Query menggunakan istilah umum dalam Bahasa Indonesia, sementara dokumen sumber berbahasa Inggris teknis. Chunk yang terambil memiliki jarak semantik L2 lebih dekat ke bagian buku lain (misalnya set latihan/practice test) daripada bab pengantar utama. Rekomendasi perbaikan: fine-tuning query expansion atau translasi dwibahasa sebelum retrieval.

7.3 Contoh Out-of-Scope (Grounding Guardrail)

Query ID: oos_01

Pertanyaan: Berapa biaya pendaftaran resmi tes TOEFL iBT dalam mata uang Rupiah pada tahun 2025 di Jakarta?

Handled correctly: Ya

Jawaban: Informasi mengenai biaya pendaftaran resmi tes TOEFL iBT dalam mata uang Rupiah untuk tahun 2025 di Jakarta **tidak ditemukan** dalam dokumen sumber yang tersedia. ■ **Sumber:** – (tidak ada data biaya spesifik dalam konteks yang diberikan) ...

8. Keterbatasan, Etika, dan Copyright

Keterbatasan:
- Sistem hanya mencakup satu dokumen sumber (edisi 2012).
- Format TOEFL dapat berubah; informasi mungkin tidak up-to-date.
- Answer correctness dan groundedness memerlukan penilaian manual.
- Kualitas embedding tergantung model yang digunakan.
- Latency tergantung pada kondisi API Groq saat evaluasi.

Etika dan Copyright:
- Dokumen sumber adalah materi berhak cipta ETS. Hanya kutipan seperlunya yang digunakan.
- PDF sumber tidak didistribusikan bersama source code.
- Sistem bukan pengganti instruktur TOEFL profesional.
- Soal latihan buatan AI diberi label jelas dan tidak diklaim sebagai soal resmi ETS.

9. Kesimpulan

Pipeline RAG TOEFL Mate telah dijalankan pada dataset evaluasi dan hasil otomatis tercatat di bagian 6. Interpretasi generation harus mengikuti status run serta error per item. Metrik manual (answer correctness, groundedness) tetap memerlukan review manusia. Konfigurasi evaluasi dicatat agar eksperimen dapat diaudit dan diulang.